

# NIPS Konferans Makalelerinin (1987-2015) Makine Öğrenmesi Algoritmaları ile Dönem Sınıflandırması

**Umut Doğan**

*Bilgisayar Mühendisliği, Teknoloji Fakültesi, Gazi Üniversitesi, Ankara, Türkiye*  
24181616058@gazi.edu.tr

**Enes Özcan Güngör**

*Bilgisayar Mühendisliği, Teknoloji Fakültesi, Gazi Üniversitesi, Ankara, Türkiye*  
24181616017@gazi.edu.tr

## ÖZET

Bu çalışmada, NIPS (Neural Information Processing Systems) konferansında yayımlanan akademik makalelerin içeriklerine göre yayımlandıkları dönemlerin tahmin edilmesi amaçlanmıştır. Veri seti olarak kullanılan 5811 makale metninden 4497 kelimelik frekans matrisi analiz edilmiştir. Makaleler 1987-2000 (Klasik Dönem) ve 2001-2015 (Modern Dönem) olarak iki ana sınıfa ayrılmıştır. Sınıflandırma problemi için Lojistik Regresyon, Basit Bayes, Karar Ağacı, Rastgele Orman, K-En Yakın Komşu (KNN), Destek Vektör Makineleri (SVM) ve Yapay Sinir Ağları (YSA) algoritmaları kullanılmıştır. Elde edilen sonuçlara göre, %94,75 doğruluk oranıyla en yüksek başarıyı YSA göstermiştir. En düşük performansı ise %59,85'lik performansla uzaklık tabanlı algoritma olan KNN göstermiştir.

**Anahtar Kelimeler:** Makine Öğrenmesi, Metin Madenciliği, NIPS Veri Seti, Yapay Sinir Ağları, Sınıflandırma

## 1. Giriş

Yapay zeka ve makine öğrenmesi alanındaki bilimsel yayınların sayısı katlanarak artmaktadır. Literatürdeki oluşan devasa metin yığını manuel olarak analiz etmek imkansız hale geldiğinden, metin madenciliği ve algoritmik sınıflandırma araştırmacılar için vazgeçilmez araçlar olmuştur. Bu çalışma 1987-2015 yılları arasındaki NIPS makalelerini temel alarak, bir makalenin kullandığı kelime dağarcığına bakarak o makalenin hangi döneme ait olduğunu tahmin etme problemine odaklanmaktadır. Bu doğrultuda makalelerden elde edilen kelime frekans matrislerinde makine öğrenmesi algoritmaları eğitilmiş ve "Hangi makine öğrenmesi algoritması akademik metinlerin tarihsel örüntülerini en yüksek doğrulukla yakalayabilir?" araştırma sorusuna yanıt aranmıştır.

### 1.1. Çalışmanın Özgün Değeri

Bu çalışmanın literatüre sunduğu başlıca özgünlük, NIPS veri setinin geleneksel araştırmalarda ağırlıklı olarak "konu modelleme" (topic modeling) amacıyla kullanılmasından farklı olarak, bir

**"zaman/dönem sınıflandırması"** problemine dönüştürülmesidir. Araştırmamız, bir makalenin konusundan bağımsız olarak, yalnızca kullandığı kelime frekanslarına bakarak yazıldığı akademik çağı (Klasik veya Modern dönem) %94,75 gibi yüksek bir doğrulukla tahmin edebilen yenilikçi bir ikili sınıflandırma yaklaşımı sunmaktadır. Ayrıca, 11.463 boyutlu devasa bir kelime matrisi üzerinde herhangi bir boyut indirgeme işlemi yapılmadan makine öğrenmesi ekolleri zorlu bir teste tabi tutulmuş; KNN algoritmasının başarısızlığı üzerinden **"Boyutluluk Laneti"** teorisi yalnızca kavramsal olarak değil, ampirik verilerle de ispatlanmıştır.

## 2. Materyal ve Yöntem

Çalışmada, makalelerden elde edilen kelime frekanslarının yer aldığı yüksek boyutlu bir matris kullanılarak, ikili sınıflandırma (binary classification) problemi modellenmiştir. Geliştirilen modeller Python programlama dili ve Scikit-Learn kütüphanesi kullanılarak tasarlanmıştır. Veri ön işleme adımında matristeki eksik (NaN) değerler, o kelimenin ilgili makalede hiç geçmediği göz önüne alınarak 0 ile doldurulmuştur.

### 2.1. Veri Seti

Kullanılan veri seti, UCI Machine Learning Repository üzerinden alınan "NIPS Conference Papers 1987-2015" veri setidir. Veri setinde toplam 5811 adet makale ve bu makalelerden çıkarılmış 4497 adet kelimenin frekans verileri bulunmaktadır. Analiz için hedef değişken yıllara göre ikiye ayrılmıştır; 1987-2000 yılları arası 0 (Klasik Dönem), 2001-2015 yılları arası ise 1 (Modern Dönem) olarak etiketlenmiştir.

### 2.2. Kullanılan Makine Öğrenmesi Algoritmaları

Çalışma kapsamında Lojistik Regresyon, Basit Bayes (Naive Bayes), Karar Ağacı (Decision Tree), Rastgele Orman (Random Forest), Destek Vektör Makineleri (SVM), K-En Yakın Komşu (KNN) algoritmaları kullanılmıştır. Ek olarak, metinlerin karmaşık örüntülerini öğrenebilmesi amacıyla Yapay Sinir Ağları (YSA) uygulanmıştır. Modeller oluşturulurken veri seti %80 eğitim %20 test seti olarak ayrılmıştır.

Modeller eğitilirken algoritmaların hiperparametreleri veri setinin yapısına uygun olarak optimize edilmiştir. Yüksek boyutlu metin verilerinde sınıfları en iyi ayıran sınır çizgisini bulabilmek için Destek Vektör Makineleri (SVM) modelinde doğrusal çekirdek olan **'linear' kernel** kullanılmıştır. K-En Yakın Komşu (KNN) algoritmasında komşu sayısı **k=5** olarak belirlenmiş ve mesafe metriği olarak Öklid (Euclidean) kullanılmıştır. Karmaşık dil örüntülerini yakalamak için kurulan Yapay Sinir Ağları (YSA / MLP) modelinde tek gizli katmanlı ve **50 nöronlu** (hidden\_layer\_sizes=(50,)) bir yapı tercih edilmiş,

modelin yakınsaması için maksimum iterasyon sayısı 500 olarak ayarlanmıştır. Lojistik Regresyon modelinin optimizasyon adımlarının tamamlanabilmesi için maksimum iterasyon sınırı 1000 yapılmıştır. Karar Ağacı ve Rastgele Orman algoritmalarında ise sonuçların bilimsel olarak tekrar edilebilirliğini sağlamak amacıyla rastgelelik durumu (random\_state=42) sabitlenmiştir.

## 2.3. Literatür Taraması

Metin sınıflandırma ve makine öğrenmesi uygulamaları üzerine literatürde çok sayıda araştırma mevcuttur. Thorsten Joachims (1998), makine öğrenmesi modellerinin özellikle de Destek Vektör Makinelerinin (SVM ) metin kategorizasyonunda oldukça verimli olduğunu göstermiştir. David Blei (2003) bilimsel makaleler üzerinde konu modellemesi gerçekleştirerek metinlerin tematik yapılarını ortaya çıkarmıştır. Mustafa Karabulut ve ark. (2015), çeşitli sezgisel algoritmaların ardışık olarak kullanıldığı iki aşamalı bir özellik seçim yöntemi önerilmiş ve bu yaklaşımın sınıflandırma performansını belirgin şekilde artırdığı gösterilmiştir. Dey (2016), farklı makine öğrenmesi algoritmalarını inceleyerek kullanım alanlarını değerlendirmiştir. Kamran Kowsari ve arkadaşları (2019) ise metin sınıflandırmada özellikle derin öğrenme ve sinir ağı mimarilerinin performans artışındaki rolünü detaylandırmıştır. Güler Alparslan ve Mahir Dursun (2023), TF-IDF kelime temsil yöntemi kullanılarak farklı veri kümeleri üzerinde makine öğrenmesi ve derin öğrenme tabanlı algoritmaların performansları değerlendirilmiş; metin türü, sınıf sayısı ve kelime vektör boyutu gibi faktörlerin sınıflandırma doğruluğu üzerindeki belirleyici etkisi kanıtlanmıştır.

## 2.4. Kod ve Veri Erişilebilirliği

Bu çalışmada gerçekleştirilen veri ön işleme, model eğitimi, performans ölçümleri ve görselleştirme adımlarına ait tüm Python (Google Colab) kaynak kodları ile araştırma raporunun son haline aşağıdaki GitHub bağlantısı üzerinden ulaşılabilir:

**GitHub Linki:** <https://github.com/UmutDogannn/NIPS-Makine-Ogrenmesi-Donem-Siniflandirmasi>


## 3. Bulgular ve Tartışma

Eğitilen yedi farklı makine öğrenmesi algoritmasının test seti (%20) üzerinde gösterdiği sınıflandırma performansları Tablo 1'de özetlenmiştir.

Tablo 1.


| Kullanılan Algoritma         | NIPS Veri Seti (Dönem Tahmini) Doğruluk Oranı |
|------------------------------|-----------------------------------------------|
| Yapay Sinir Ağları (YSA)     | 0,9475                                        |
| Rastgele Orman               | 0,9175                                        |
| Lojistik Regresyon           | 0,9037                                        |
| SVM (Destek Vektör Makinesi) | 0,8917                                        |
| Basit Bayes                  | 0,8641                                        |
| Karar Ağacı                  | 0,8323                                        |
| K-En Yakın Komşu (KNN)       | 0,5985                                        |

**ŞEKİL 1: Algoritma Performans Karşılaştırması (11.463 Öznitelik)**



Tablo 1 ve Şekil 1 incelendiğinde, kelime matrisi üzerinde en başarılı sonucun %94,75 doğruluk oranıyla Yapay Sinir Ağları (YSA) tarafından elde edildiği görülmektedir. YSA'yı sırasıyla Rastgele Orman (%91,75) ve Lojistik Regresyon (%90,37) izlemiştir. Yüksek boyutlu uzaylarda etkili olan Destek Vektör Makineleri (SVM) de %89,17 ile oldukça iyi bir sonuç vermiştir. Buna karşılık, K-En Yakın Komşu (KNN) algoritması %59,85'lik oranla en düşük performansı sergilemiştir. Bu durum, öznitelik (kelime) sayısının 11.463 gibi çok yüksek bir seviyeye çıkmasından kaynaklanan "boyutluluk laneti" sebebiyle uzaklık ölçümlerinin verimliliğini kaybetmesi ile açıklanmaktadır. Karar ağaçlarının tek başına kullanılması aşırı öğrenme (overfitting) problemine yatkınlığı nedeniyle %83,23'te kalırken, Rastgele Orman algoritmasında performansın belirgin bir şekilde arttığı gözlemlenmiştir.

**ŞEKİL 2: Yüksek Boyutluluğun KNN Performansına Etkisi**



Literatürde "Boyutluluk Laneti" olarak bilinen bu matematiksel olgu; boyut sayısı çok arttığında veri uzayı hacminin üssel olarak büyümesi ve noktalar arasındaki uzaklık farklarının birbirine çok yaklaşarak anlamını yitirmesi durumudur. Mesafe kavramının ayırt ediciliğini kaybetmesiyle KNN algoritması hedef "komşularını" doğru tespit edemez hale gelmiş

#### 4. Sonuç ve Öneriler

Bu araştırmada NIPS konferanslarına ait akademik metinlerin sadece kelime kullanım frekansları incelenerek makalelerin dönemlerinin (1987-2000 klasik veya 2001-2015 modern dönem) tahmin edilebileceği gösterilmiştir. Sonuçlar, karmaşık yapıdaki dil örüntülerini çözmede Yapay Sinir Ağlarının klasik makine öğrenmesi modellerinden daha üstün olduğunu doğrulamıştır. Gelecek çalışmalarda, TF-IDF gibi ağırlıklandırma yöntemlerinin veri ön işleme aşamasına dahil edilmesi önerilmektedir.

#### KAYNAKÇA

1. Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of machine Learning research*, 3(Jan), 993-1022.
2. Dey, A. (2016). Machine Learning Algorithms: A Review. *International Journal of Computer Science and Information Technologies*, 7(3): 1174-1179.
3. Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. *European conference on machine learning*, Springer.
4. Kowsari, K., Jafari Meimandi, K., Heidarysafa, M., Mendu, S., Barnes, L., & Brown, D. (2019). Text classification algorithms: A survey. *Information*, 10(4), 150.
5. Haltaş, A., Alkan, A., & Karabulut, M. (2015). Metin sınıflandırmada sezgisel arama algoritmalarının performans analizi. *Gazi Üniversitesi Mühendislik-Mimarlık Fakültesi Dergisi*, 30(3), 417-427.
6. Alparslan, G., & Dursun, M. (2023). Konvolüsyonel sinir ağları tabanlı Türkçe metin sınıflandırma. *Bilişim Teknolojileri Dergisi*, 16(1), 21-31.
7. UCI Machine Learning Repository. (2015). NIPS Conference Papers 1987-2015. Erişim adresi: <https://archive.ics.uci.edu/dataset/371/nips+conference+papers+1987+2015>